

폭염은 왜 누구에게 더 잔인한가

설명가능 AI(XAI)로 서울의 열 리스크를 해부한 이야기, 그리고 국제 학술지에 실리기까지

안녕하세요. 오늘은 제가 제 1 저자로 국제 학술지 **Urban Climate**(임팩트 팩터 6.9, 해당 분야 상위 6%)에 게재한 연구를 처음부터 끝까지 풀어서 이야기해 보려고 합니다. 논문은 영어로 딱딱하게 쓰여 있지만, 사실 이 연구가 던지는 질문은 아주 단순합니다.

"같은 폭염인데, 왜 어떤 동네는 더 많이 죽는가?"

여름마다 뉴스에서 "오늘 서울 최고기온 36 도"라는 말을 듣습니다. 그런데 그 36 도는 서울 어디에서나 똑같은 36 도가 아닙니다. 어떤 동네에서는 그냥 더운 하루이고, 어떤 동네에서는 누군가의 마지막 하루가 됩니다. 저는 이 차이가 어디서 오는지를 데이터로 규명하고 싶었습니다. 그리고 더 중요하게는, **왜 그런지 설명할 수 있는** 모델을 만들고 싶었습니다.

이 글은 전공자가 아니어도 읽을 수 있도록, 어려운 용어가 나오면 그때그때 풀어서 설명하겠습니다. 조금 길지만 천천히 따라오시면 "AI 로 기후 리스크를 평가한다"는 말이 실제로 무엇을 하는 일인지 감이 잡히실 거예요.

기후정의를 위한 설명가능한 인공지능 (XAI)

GAT와 AR6프레임워크 기반 서울시 시공간 열 리스크 평가
최희도¹, 임철희^{1†}

¹국민대학교 산림환경시스템학과

Global Climate Change, Innovative Modeling and Monitoring (CLIM)
Laboratory
Kookmin University



그림 1. 연구 발표 표지입니다. 제목은 '기후정의를 위한 설명가능한 인공지능(XAI): GAT 와 AR6 프레임워크 기반 서울시 시공간 열 리스크 평가'로, 한국기후변화학회 우수대학원생지원프로그램 발표 자료이기도 합니다.

1. 시작은 "지도 한 장이 이상하다"는 느낌이었습니다

폭염 연구를 하다 보면 '열 취약성 지도'를 자주 봅니다. 빨간색은 위험, 파란색은 안전. 그런데 저는 이 지도들을 보면서 계속 찜찜한 기분이 들었습니다. 이 지도는 대체 **무엇을 근거로** 이 동네를 빨강게 칠했을까요?

기존 방식은 대부분 이렇게 만듭니다. 폭염일수, 고령인구 비율, 녹지 면적 같은 변수를 여러 개 모아서, 각각에 가중치를 곱해 더합니다. 예를 들어 "폭염일수 30% + 고령인구 40% + 녹지 30%" 같은 식이죠. 이게 **열 취약성 지수(HVI, Heat Vulnerability Index)**입니다.

문제는 이 30%, 40%라는 숫자를 **연구자가 정한다는 것**입니다. 왜 40%인가요? 왜 35% 아닌가요? 명확한 답이 없습니다. 연구자가 바뀌면 지도의 색깔도 바뀝니다. 게다가 이렇게 만든 지수가 실제 온열질환 발생과 얼마나 맞는지 검증한 연구도 드물었습니다.

그럼 요즘 유행하는 딥러닝을 쓰면 될까요? 정확도는 올라갑니다. 그런데 이번엔 반대 문제가 생깁니다. **왜 그렇게 예측했는지 아무도 모릅니다**. 이걸 '블랙박스'라고 부릅니다. 정확하지만 설명할 수 없는 모델은 정책 근거로 쓰기 어렵습니다. 공무원이 "이 동네에 예산을 더 써야 합니다"라고 보고할 때, 근거가 "AI가 그렇게 말했습니다"일 수는 없으니까요.

01. 연구배경

2 기존 방법론

- 기후변화로 심화되는 도시 열섬 현상은 사회경제적 요인에 따라 차별적인 건강 피해를 야기하며(IPCC, 2022), 이는 기존의 구조적 불평등을 극대화하는 기후정의의 핵심 과제로 대두되고 있다.
- 이에 형평성 기반의 도시 기후 적응 전략이 시급히 요구되고 있으나(Rosenzweig et al., 2018), 적응 정책의 기반이 되는 기존 열 리스크 평가는 방법론적 한계에 직면해 있다.
- 기존의 열 취약성 지수(HVI) 연구들은 지표 선정과 가중치 부여의 주관성, 그리고 실제 건강 피해 데이터와의 실증적 검증 부재로 인해 정책적 신뢰성을 확보하지 못하고 있다(Cheng et al., 2021; Niu et al., 2021).

방법론 유형	핵심 한계	검증 결과
HVI (기존 지수)	• 이론/지표의 비일관성 • 주관적 가중치 설정 • 통계적 가중치(PCA)의 한계 • 공간 단위 설정에 따른 통계적 왜곡 (MAUP)	검증 부재 (전체 연구의 26.9%만 검증 수행) 낮은 실증적 타당성 (R^2 검증 결과) 연구 간 불일치 (R^2 값이 0.04 ~ 0.62로 편차가 큼)
AI (선형 모델)	• 기온-인구 밀도 등 비선형 상호작용 포착 실패 • 도시 시스템의 시공간적 변동을 반영 못하는 정적 평가	임계 효과 누락 복합 리스크 요인을 단순화
DL (딥러닝)	• 예측 근거를 설명 못하는 블랙박스 문제 • 단일 XAI 기법 적용으로 인한 해석의 신뢰성 부족	정책 결정자의 신뢰도 저하 XAI 기법 간 교차 검증 부재로 인한 해석 불일치

이러한 방법론적 한계를 극복하기 위해, IPCC AR6 리스크 프레임워크에 기반한 설명가능한(XAI) 시공간 그래프 어텐션 네트워크(GAT)를 개발하여, 서울시 열 리스크의 복잡한 상호작용을 정량적으로 평가하고 기후 적응 정책을 위한 실증적 근거를 제시하고자 한다.

03

그림 2. 기존 접근법들의 한계를 정리한 슬라이드입니다. 왼쪽의 HVI 방식은 가중치를 사람이 임의로 정하고, 가운데 AI 방식은 정확하지만 설명이 안 되며, 오른쪽 딥러닝은 검증이 부족하다는 문제가 각각 있었습니다.

정확도와 설명력을 동시에 가진 방법이 비어 있었던 셈입니다.

정리하면 제가 마주한 상황은 이랬습니다. **정확한 모델은 설명을 못 하고, 설명이 되는 모델은 근거가 주관적이다**. 이 둘을 동시에 잡는 것이 이 연구의 출발점이었습니다.

2. 해결의 실마리는 IPCC 보고서에 있었습니다

여기서 저는 방향을 조금 틀었습니다. 가중치를 제가 정하는 대신, **이미 국제적으로 합의된 이론 틀을 가져와서 AI에 심으면 어떨까?**

기후변화 분야에서 가장 권위 있는 문서가 IPCC 평가보고서입니다. 가장 최신인 제 6차 보고서(AR6)는 '위험(Risk)'을 이렇게 정의합니다. 위험은 다음 네 가지가 만나서 생긴다는 것입니다.


- **위해(Hazard)** — 폭염 그 자체의 강도. 며칠이나 더웠는지, 얼마나 뜨거웠는지.
- **노출(Exposure)** — 그 더위에 얼마나 많은 사람과 자산이 노출되어 있는지. 인구밀도, 건물밀도, 불투수면 비율 같은 것들.
- **취약성(Vulnerability)** — 노출된 사람들이 얼마나 약한지. 고령인구, 영유아, 저소득층, 지하주거 비율 등.
- **적응역량(Adaptive Capacity)** — 대응할 수 있는 힘. 무더위쉼터, 의료 접근성, 냉방 전력, 녹지 등.

즉 **위험 = f(위해, 노출, 취약성, 적응역량)** 입니다. 이 구조는 제가 만든 게 아니라 전 세계 과학자들이 합의한 것이고, 그래서 "왜 이 네 가지인가?"에 대한 답이 이미 마련되어 있습니다.

제 아이디어는 이 네 요소를 **AI 모델의 구조 자체에 물리적으로 심는** 것이었습니다. 변수를 그냥 한 통에 넣고 섞는 게 아니라, 네 요소를 각각 별도의 경로로 학습시키고 마지막에 결합하는 방식이죠. 그러면 학습이 끝난 뒤 "이 지역의 위험에서 위해가 몇 %, 노출이 몇 %를 기여했는가"를 이론에 맞춰 분해할 수 있습니다.

01. 연구배경

3 연구 목적 및 접근법



연구 목적

- IPCC AR6 프레임워크 기반 설명가능한 시공간 그래프 어텐션 네트워크 개발 및 다중 XAI 교차 검증
- 실제 건강 데이터와의 비선형 연관성 분석을 통한 모델의 실증적 타당성 입증
- 리스크 지배 요인의 스케일별 전환 규명 및 기후정의를 위한 정책 근거 제시

04

그림 3. IPCC AR6의 위험 개념을 이 연구의 모델 구조로 옮긴 그림입니다. 왼쪽 네 개의 잎 모양이 위해·노출·취약성·적응역량이고, 오른쪽이 이를 그래프 신경망으로 통합해 도시 열 리스크를 산출하는 구조입니다. 이론이 모델 안에 그대로 들어가 있다는 점이 핵심입니다.

3. 왜 하필 '그래프' 신경망이었을까요

모델을 고를 때 한 가지를 더 고민했습니다. 도시의 더위는 **행정동 경계를 존중하지 않습니다**. 옆 동네가 아파트 숲이고 아스팔트로 덮여 있으면, 우리 동네 기온도 같이 올라갑니다. 열은 번지니까요.

그런데 기존 통계 모형은 대개 각 지역을 독립된 점으로 봅니다. 강남구는 강남구, 서초구는 서초구. 이러면 '옆 동네 효과'를 놓칩니다.

그래서 **그래프 어텐션 신경망(GAT, Graph Attention Network)**을 선택했습니다. 이름이 어렵지만 개념은 직관적입니다.

• 서울의 각 지역(행정동)을 **점(노드)**으로 놓습니다.


• 인접한 지역끼리 **선(엣지)**으로 연결합니다.

• 그리고 모델이 스스로 "**어느 이웃이 나에게 더 중요한가**"를 학습합니다. 이게 '어텐션(주목)'입니다.

즉 모든 이웃을 똑같이 취급하지 않고, "이 동네의 더위에는 북쪽 이웃보다 남쪽 이웃의 영향이 크다"는 식의 가중치를 데이터로부터 알아냅니다. 사람이 정해주는 게 아니라 모델이 찾아냅니다.

02. 연구 방법

2 GAT 모델 아키텍처



06

그림 4. 제안한 모델의 전체 아키텍처입니다. 왼쪽부터 물리 제약을 반영한 입력, 시공간 정보를 결합하는 단계, AR6 네 요소를 교차 결합하는 GAT 층, 그리고 불확실성까지 함께 내놓는 위험 예측으로 이어집니다. 각 단계가 이론적 역할을 하나씩 담당하도록 설계했습니다.

여기에 시간 축도 넣었습니다. 폭염은 하루 사건이 아니라 며칠씩 이어지며 누적됩니다. 그래서 시계열 학습이 가능한 구조를 결합해, **공간(어디)과 시간(언제)을 동시에** 다루도록 했습니다. 이걸 '시공간 모델'이라고 부릅니다.

4. 가장 신경 쓴 부분은 "정직하게 검증하기"였습니다

솔직히 말씀드리면, 이 연구에서 제가 가장 오래 붙잡고 있었던 건 모델 성능을 올리는 일이 아니었습니다. **성능을 부풀리지 않는 일**이었습니다.


공간 데이터에는 함정이 있습니다. 가까운 동네끼리는 지형·건물·인구가 서로 닮아 있습니다. 그래서 학습용과 검증용 데이터를 무작위로 섞으면, 모델이 "옆 동네 정답"을 슬쩍 보고 답을 맞히는 셈이 됩니다. 성적표는 화려해지지만 실력은 아닙니다. 이걸 **정보 누출(data leakage)**이라고 합니다.

그래서 세 가지 방식으로 일부러 어렵게 검증했습니다.

- **시간 순방향 검증**(Temporal Forward Chaining): 과거로 학습하고 미래를 예측합니다. 미래를 미리 보지 못하게 막는 방식입니다.
- **공간 블록 교차검증**(Spatial Block CV): 지역을 덩어리로 잘라내고, 아예 학습에서 본 적 없는 지역을 맞히게 합니다.
- **권역 단위 검증**(Nested LORO): 서울을 5 개 권역으로 나눠, 한 권역을 통째로 빼고 학습한 뒤 그 권역을 예측합니다.

02. 연구 방법

2 GAT 모델 아키텍처



- IPCC AR6 이론에 기반하여 각 컴포넌트(H, E, S, AC)의 물리적 특성(예: 양수 제약, 적응능력의 리스크 상쇄 효과)을 활성화 함수 단계에서 구조적으로 반영
- 학습 가능한 파라미터(α)를 통해 데이터 특성에 맞는 최적의 공간적 이웃(KNN)과 시간적 흐름(Temporal Decay) 비율을 동적으로 학습
- 다중 GAT 레이어를 통해 이질적인 기후 요소들 간의 비선형 상호작용 가중치를 학습



1. 시공간 정보 누수 방지
 - 높은 자기상관성을 가진 시공간 데이터의 특성을 고려하여, 미래 시점 및 미관측 지역을 테스트셋으로 완전히 분리하는 교차 검증 수행
 2. 다중 목적 손실 기반 커리큘럼 러닝
 - 복합 손실 함수 정의: 모델의 다각적 성능 확보를 위해 네 가지 손실 항을 결합한 최적화 수행
- $$L_{\text{Total}} = \lambda_1 L_{\text{Recon}} + \lambda_2 L_{\text{DGI}} + \lambda_3(t) L_{\text{Physics}} + \lambda_4 L_{\text{Reg}}$$
- 단계적 학습 전략:
 (초기): 데이터 재구성(L_{Recon})과 그래프 구조 학습(L_{DGI})에 집중하여 기본적인 시공간 패턴을 포착.
 - 시간에 따라 가중치 λ_3 를 점진적으로 증가시키는 동적 스케줄링 적용.
 - (후기): 이론 기반 손실 L_{Physics} 의 비중을 높여, IPCC 이론적 기반을 갖춘 일관성 있는 모델로 최종 최적화 유도.

* L_{Physics} : IPCC AR6 이론에 기반하여 부과되는 패널티. 위험 증가 요인(Hazard, Exposure, Sensitivity)의 음의 기울기 또는 위험 감소 요인(Adaptive Capacity)의 양의 기울기 발생 시, 해당 기울기의 크기만큼 손실값이 증가하여 모델이 물리적 정합성을 준수하도록 유도함.

08

그림 5. 모델 내부에 넣은 엄격성 검증 장치입니다. 시간 정보와 공간 정보가 서로 새어 들어가지 못하도록 차단하는 구조를 모델 설계 단계에서부터 넣었습니다. 성능이 좋아 보이게 만드는 것보다, 좋아 보이는 이유가 진짜인지가 더 중요했습니다.



결과부터 말씀드리면, 이렇게 까다롭게 검증했음에도 **결정계수(R²)가 0.9681**로 나왔습니다.

R²는 모델이 실제 값의 변동을 얼마나 설명하는지를 0~1로 나타내는 지표인데, 0.97에 가깝다는 건 상당히 잘 맞았다는 뜻입니다. 오차(RMSE)는 0.162였습니다.

03. 연구 결과

1 모델 성능 및 검증

- Temporal Forward Chaining (미래 예측) 결과
 - 과거 데이터로 학습 후, 바로 다음 해를 테스트하는 과정을 매년 반복 수행 (미래 정보 누수 원천 차단).
 - 3년 연속 테스트 평균 $R^2 = 0.9681 (\pm 6.79 \times 10^{1-2})$, RMSE = 0.162 달성.
 - 매년 새로운 기후 패턴이 나타나도 안정적이고 정확한 미래 예측 성능 유지 확인
- Spatial Block CV (미관측 지역 예측) 결과
 - 5개 권역 중 하나를 테스트셋으로 완전히 분리하는 5-fold 교차 검증 수행
 - 모든 권역에서 균일하게 높은 성능 기록 (최소 $R^2 = 0.9675$, 최대 $R^2 = 0.9691$).
 - 매년 새로운 기후 패턴이 나타나도 안정적이고 정확한 미래 예측 성능 유지 확인
- Nested LORYO (미관측 지역 및 시점) 결과
 - 시공간(연도 $\times$ 권역) 조합을 하나씩 제외하는 검증에서도 성능 저하 없음
 - 어떠한 시공간적 제약 조건하에서도 모델의 예측 신뢰성 확보



Validation Method	Configuration	Score	RMSE
Temporal Forward CV	2015-2016 → 2017	0.9682	0.161
	2015-2017 → 2018	0.9681	0.162
	2015-2018 → 2019	0.9681	0.162
Mean $\pm$ SD		$0.9681 \pm 6.79 \times 10^{-2}$	0.162
Spatial Block CV	5-fold regional	0.9681	0.163
	Region 0 (624 pts/yr)	0.9689	0.159
	Region 1 (580 pts/yr)	0.9669	0.164
	Region 2 (684 pts/yr)	0.9691	0.158
	Region 3 (746 pts/yr)	0.9675	0.162
Nested Spatiotemporal	20 Region-Year combos	0.9682	0.161
	LORYO (Most Strict)	0.9682	0.161

10

그림 6. 세 가지 방식으로 검증한 성능표입니다. 시간 순방향, 공간 블록, 권역 단위 검증 모두에서 R^2 가 0.96 이상으로 유지되었습니다. 특정 검증 방식에서만 잘 나오는 게 아니라는 점이 중요합니다.

여기에 하나 더, 변수들끼리 지나치게 겹쳐서 결과가 왜곡되지 않는지(다중공선성), 그리고 모델이 학습한 관계가 이론적으로 말이 되는 방향인지도 따로 확인했습니다. 예를 들어 '고령인구가 늘면 위험이 올라간다'처럼 상식과 이론에 부합하는 부호가 나오는지를 하나하나 점검한 것입니다.

03. 연구 결과

1 모델 성능 및 검증

- GAT 기반 리스크 정보 증폭
 - GAT 레이어 통과 후 출력 임베딩의 분산이 입력 대비 약 1.79~2.15배 증가함. 이는 모델이 시공간 맥락을 학습하여 단순 입력 정보보다 뚜렷하고 변별력 있는 리스크 특징을 추출했음
- AR6 컴포넌트 상호작용 학습
 - 어텐션 가중치 분석 결과, *Sensitivity* ↔ *Adaptive Capacity*(2.079) 등 높은 연결 강도가 확인됨. IPCC 이론의 컴포넌트 간 비선형 시너지 및 상쇄 효과를 모델이 실제로 학습
- 다중공선성 해소
 - 임베딩 공간에서 컴포넌트 간 상관관계(예: *Hazard* ↔ *Exposure* 0.272 → 0.018)의 높은 상관성 문제를 해결하고 각 요소의 독립적 기여도를 분리
- 이론 타당성 확보
 - 주요 변수와 예측 리스크 간의 상관관계가 이론적 방향성과 일치하여, 물리적 제약 기반 학습($L_{physics}$)의 유효성을 확인.

Relationship Test	Observed Correlation	P-value	Expected Direction
Green Space ↔ Risk	-0.0332	1.41×10^{-4}	Negative
Elderly Population ↔ Risk	+0.3405	< 0.001	Positive
Low income ↔ Risk	+0.2891	< 0.001	Positive
Impervious surface ↔ Risk	+0.4011	< 0.001	Positive

Analysis Component	Metric	Value
GAT Attention Enhancement		
Hazard variance	Input → Output	0.0662 → 0.1186 (1.79×)
Exposure variance	Input → Output	0.0594 → 0.1173 (1.98×)
Sensitivity variance	Input → Output	0.0289 → 0.0620 (2.15×)
Adaptive variance	Input → Output	0.0216 → 0.0434 (2.01×)
AR6 Component Interactions		
Sensitivity ↔ Adaptive	-	2.079
Exposure ↔ Sensitivity	-	2.062
Hazard ↔ Sensitivity	-	1.970
Exposure ↔ Adaptive	-	1.993
Hazard ↔ Sensitivity	-	1.970
Hazard ↔ Adaptive	-	1.901
Multicollinearity Resolution		
Hazard ↔ Exposure	Before → After	0.272 → 0.018 (-93.4%)
Hazard ↔ Sensitivity	Before → After	0.216 → 0.069 (-68.1%)
Exposure ↔ Sensitivity	Before → After	0.804 → 0.051 (-93.7%)
Sensitivity ↔ Adaptive	Before → After	0.046 → 0.004 (-91.3%)

11

그림 7. 변수 간 상관과 이론 정합성을 점검한 결과입니다. 예를 들어 녹지가 늘면 위험이 내려가고 고령인구가 늘면 위험이 올라가는 등, 모델이 학습한 관계의 방향이 기존 이론과 일치하는지를 확인했습니다.

5. 모델에게 "왜?"라고 세 번 물었습니다


이제 이 연구의 핵심입니다. 예측이 잘 되는 것만으로는 부족하고, **왜 그렇게 판단했는지**를 알아야 합니다. 그래서 설명가능 AI(XAI) 기법을 하나가 아니라 **세 가지**를 동시에 적용했습니다.

- **SHAP** — 각 변수가 예측값을 얼마나 밀어 올리거나 내렸는지 기여도를 나눠 계산합니다. 게임이론에서 나온 방법입니다.
- **GNNExplainer** — 그래프 구조에서 어떤 연결이 결정적이었는지를 찾아냅니다. "이 판단에는 이 이웃 관계가 중요했다"를 알려줍니다.
- **Integrated Gradients** — 입력을 조금씩 바꿔가며 예측이 변하는 경로를 추적합니다.

세 개를 쓴 이유는 명확합니다. 한 기법만 쓰면 그 기법의 편향인지 진짜 신호인지 구분할 수 없기 때문입니다. 서로 원리가 완전히 다른 세 방법이 **같은 결론을 낸다면**, 그건 방법의 착시가 아니라 데이터에 실제로 있는 구조라고 볼 수 있습니다.

02. 연구 방법

2 Multi - XAI 검증 및 외부 건강 데이터 검증



1. XAI 검증 체계
 - SHAP : 각 요인이 리스크 예측에 얼마나 공정하게 기여했는지 계산
 - GNNExplainer : 예측에 핵심적인 영향을 미친 공간적 서브그래프 및 구조적 특징
 - Integrated Gradients : 입력값이 변할 때 리스크가 어떻게 동적으로 바뀌는지 추적
2. 해석의 일관성 및 신뢰성 검증
 - 서로 다른 XAI 기법들이 내놓은 주요 요인의 순위가 얼마나 일치하는지 분석
3. 실제 건강 데이터 기반 비선형 검증
 - 단순한 선형 관계뿐만 아니라 복잡한 비선형 관계까지 포착할 수 있는 거리 상관계수(Distance Correlation)를 도입하여, 실제 건강 피해와의 연관성을 분석

09

그림 8. 세 가지 XAI 기법을 교차 적용한 구조입니다. 왼쪽은 기여도 분해, 가운데는 그래프 구조 설명, 오른쪽은 경로 추적 방식이며, 여기에 외부 건강 데이터로 한 번 더 검증하는 단계까지 붙였습니다.


결과는 기대 이상이었습니다. 세 기법의 변수 중요도 순위가 **평균 89.6% 일치**했고, 순위 상관(Spearman ρ)은 약 **0.89**($p < 0.001$)였습니다. 특히 AR6 네 요소의 위계는 **100% 일치**, 개별 변수 순위는 95% 일치했습니다. 5 년간의 시계열 해석은 85%, 5 개 권역의 공간 패턴은 80% 일치했습니다.

03. 연구 결과

4 Multi-XAI 일관성 검증

- 이질적 기법 간 해석 일관성
 - 서로 다른 원리의 세 가지 XAI 기법(SHAP, GNNExplainer, IG) 간 특성 중요도 순위를 비교한 결과, 평균 89.6%의 높은 일치도와 강한 Spearman 순위 상관관계($\rho \approx 0.89, p < 0.001$)를 확인하여 특정 방법에 편향되지 않는 객관적 해석임.
- 다차원적 해석 안정성 확보
 - 컴포넌트(95~100% 일치), 5년간의 시계열(85% 일치), 5개 권역 공간 패턴(80% 일치) 등 모든 차원에서 높은 일관성을 유지하여 모델의 시공간적 강건성과 IPCC 이론 학습의 안정성을 입증하였음.

Analysis Method	Analysis Scope	Methods Used	Consistency	Spearman ρ	p-value
Global Importance	13,170 points	SHAP + GNNExplainer + IG	89.6%	0.89	<0.001
Feature Ranking	16 AR6 variables	All methods	95.0%	0.85	<0.001
Component Hierarchy	4 AR6 components	All methods	100.0%	0.92	<0.001
Temporal Consistency	2015-2019 (5 years)	SHAP + IG	85.0%	0.81	<0.001
Temporal Trends	5-year progression	SHAP + IG	90.0%	0.83	<0.001
Spatial Patterns	5 Scout regions	GNNExplainer + IG	80.0%	0.78	<0.001
Regional Analysis	District-level	GNNExplainer + IG	85.0%	0.80	<0.001
SHAP ↔ GNNExplainer	13,170 points	-	-	0.87	<0.001
SHAP ↔ Integrated Gradients	13,170 points	-	-	0.85	<0.001
GNNExplainer ↔ IG	13,170 points	-	-	0.82	<0.001



14

그림 9. 세 XAI 기법의 일관성을 정리한 표와 그래프입니다. 왼쪽 표에서 분석 차원별 일치도(89.6%~100%)와 순위 상관을 확인할 수 있고, 오른쪽 막대그래프들은 각 기법이 뽑은 상위 변수들입니다. 서로 다른 원리의 방법들이 거의 같은 변수를 지목했다는 점이 이 연구의 신뢰를 뒷받침합니다.

이 정도면 "우연히 그렇게 보인 것"이라고 말하기 어렵습니다.

6. 그런데 정말 놀라운 발견은 여기서 나왔습니다

여기까지는 "잘 만들었다" 수준의 이야기입니다. 제가 이 연구에서 가장 흥미로웠던 순간은 분석 범위를 바꿔봤을 때 찾아왔습니다.

서울 전체를 한 번에 놓고 "무엇이 지역 간 위험 차이를 만드는가"를 물었을 때, 답은 이랬습니다.

- 도시 노출(Urban Exposure) **33.7%**
- 사회적 민감도(Social Sensitivity) **28.2%**

· 기후 위해(Climate Hazard) 23.6%

· 적응역량(Adaptive Capacity) 14.5%

즉 폭염 자체보다 도시의 물리적 구조와 사회경제적 취약성이 더 크게 작용했습니다. 어떤 동네가 더 위험한지는 '얼마나 더웠는지'보다 '어떻게 지어진 동네인지, 누가 사는지'가 결정한다는 뜻입니다.


그런데 분석 단위를 서울 전체에서 5 개 권역으로 좁히자 순위가 뒤집혔습니다. 모든 권역에서 기후 위해가 62~68%로 압도적 1 위가 된 것입니다.

03. 연구 결과

3 핵심 발견 - 스케일 전환

- 글로벌 스케일의 구조적 요인 지배
 - 서울시 전체의 거시적 분석에서는 도시 노출도(Urban Exposure, 33.7%)와 사회적 민감도(28.2%)가 기후 위험(Climate Hazard, 23.6%)을 압도하며 리스크의 주된 요인으로 나타남.
 - 이는 도시의 물리적 구조와 사회경제적 취약성이 기후 현상 자체보다 지역 간 리스크 격차를 만드는 근본 원인임을 시사.
- 서울 권역 단위로의 리스크 요인 전환:
 - 분석 단위를 5개 권역으로 축소할 경우, 리스크 지배 요인이 기후 위험(Climate Hazard)으로 급격히 전환되는 현상이 관찰됨.
 - 모든 권역에서 당장의 폭염 강도(Hazard)가 다른 구조적 요인들을 압도하는 영향력을 보임.

➡ “어떤 지역이 더 위험한가(지역 간 격차)”는 도시 구조가 결정하지만, “특정 지역이 직면한 실제 위험”은 미시적 기후 강도가 결정한다는 도시 기후 리스크의 이중적이고 스케일 의존적인 특성을 확인하였음.



13

그림 10. 스케일에 따라 지배 요인이 바뀌는 현상을 보여주는 그림입니다. 왼쪽은 서울 전체 기준으로, 도시 노출(33.7%)이 기후 위해(23.6%)를 앞섭니다. 오른쪽은 5 개 권역별로 본 것인데, 모든 권역에서 기후 위해(보라색)가 62~68%로 다른 요소를 압도합니다. 같은 데이터, 같은 모델인데 보는 범위만 바꿨더니 결론이 달라졌습니다.

이 결과를 처음 봤을 때 한동안 화면만 봤습니다. 그리고 이렇게 정리했습니다.

"어떤 지역이 더 위험한가(지역 간 격차)"는 도시 구조가 결정하지만, "특정 지역이 실제로 직면하는 위험의 크기"는 그날의 기후 강도가 결정한다.


말장난처럼 보이지만 정책적으로는 아주 중요한 구분입니다. 장기적으로 지역 간 폭염 불평등을 줄이려면 도시 구조와 사회 안전망을 손봐야 합니다. 반면 이번 주 폭염 특보에 대응하려면 기온이 실제로 치솟는 곳에 자원을 보내야 합니다. 둘은 다른 문제이고, 둘 다 필요합니다.

또 하나 눈에 띈 건 공간 패턴이었습니다. 위험은 무작위로 흩어져 있지 않고 덩어리로 뭉쳐 있었습니다. 국지적 공간통계(LISA)로 확인해 보니 고위험 지역끼리 붙어 있는 '고위험 군집(High-High)'이 통계적으로 유의하게 나타났습니다.

03. 연구 결과

2 공간 패턴 - LISA 클러스터

- 통계적 공간 군집성 규명
 - LISA 분석을 통해 도시 열 리스크의 강한 공간적 자기상관성과 통계적으로 유의미한 군집 패턴을 확인.
- 도심부 고위험 핫스팟(HH) 집중
 - High-High(HH) 클러스터가 전체의 43.5%를 차지하며, 가장 높은 평균 리스크(0.687 ± 0.082)와 유의미한 Z-score($2.34 \sim 5.67$)를 기록됨. 이는 리스크가 도심 상업 및 노후 주거 밀집 지역에 집중되어 있음을 시사함.
- 리스크의 공간적 양극화 입증
 - Low-Low(LL) 클러스터는 주로 도시 외곽 및 산림, 하천 인근에 분포.
 - HH와 LL 클러스터의 뚜렷한 공간적 분리는 서울시 내 기후 리스크의 심각한 공간적 불평등을 정량적으로 입증하며, 기후 정의 실현을 위한 우선적 정책 개입 지역을 특정함.



Cluster Type	Grid Count	Percentage	Mean Risk Score	Std Dev	Z-score Range
High-High (HH)	1,147	43.5%	0.687 ± 0.082	0.082	2.34 to 5.67
Low-Low (LL)	889	33.7%	0.312 ± 0.067	0.067	-4.89 to -2.01
High-Low (HL)	235	8.9%	0.623 ± 0.074	0.074	1.89 to 3.12
Low-High (LH)	363	13.8%	0.389 ± 0.071	0.071	-2.45 to -0.98

12

그림 11. 국지적 공간통계로 찾아낸 위험 군집 지도입니다. 붉은 영역이 고위험끼리 인접한 군집, 파란 영역이 저위험 군집입니다. 위험이 특정 지역에 뭉쳐 있다는 것은 대응도 개별 동이 아니라 권역 단위로 묶어서 해야 효율적이라는 뜻입니다.

7. "그래서 이 모델이 현실을 맞히긴 하나요?"

모델이 아무리 정교해도 실제 건강 피해와 무관하다면 의미가 없습니다. 그래서 마지막으로 **외부 데이터로 검증**했습니다. 모델 학습에 전혀 쓰지 않은 국민건강보험공단(NHIS)과 질병관리청(KDCA)의 온열질환 자료를 가져와서, 모델이 예측한 위험도와 비교했습니다.

결과는 이랬습니다.

- 인구당 여름철 온열질환 발생률과의 거리상관(dCor) **0.449** ($p < 0.001$)
- 인구당 연간 온열질환 **0.422**, 인구당 여름철 응급실 방문 **0.397**
- 상위 3 개 지표가 **모두 인구당 보정 지표**였습니다.

여기서 '거리상관'은 선형 관계만 잡는 일반 상관계수와 달리 **휘어진 관계까지 잡아내는 지표**입니다. 폭염과 건강 피해의 관계는 직선이 아니라 어느 임계를 넘으면 급격히 나빠지는 형태라, 이 지표가 더 적절합니다.


그리고 시차(lag) 분석에서 **당해 연도의 상관**이 가장 높게 나왔습니다(평균 $dCor \approx 0.423$). 즉 이 모델이 잡아내는 위험은 몇 년 뒤에 서서히 나타나는 만성 영향이 아니라, **그 여름에 바로 사람을 아프게 하는 급성 영향**이라는 뜻입니다.

03. 연구 결과

5 건강 데이터 외부 검증

- 실제 건강 피해와의 유의미한 비선형 연관성 입증
 - 다기관 보건 데이터(NHIS, KDCA)를 활용한 외부 검증 결과, 모델의 예측 리스크가 실제 온열질환 발생과 통계적으로 유의미한 비선형 연관성을 보임.
 - 특히 인구당 여름철 온열질환 발생률과 가장 높은 거리 상관계수($dCor = 0.449, p < 0.001$)를 기록하여, 단순 선형 관계를 넘어선 복잡한 실제 피해 구조를 효과적으로 포착했음을 증명.
- 인구 보정 지표 및 즉각적 영향 반영 확인
 - 상위 3개 지표가 모두 인구당 보정 지표로 나타나, 단순 발생 건수보다 지역별 인구 구조를 고려한 리스크 평가가 더 정확함.
 - 시간 지연(Lag) 분석 결과, 당해 연도(0-year lag)의 상관성이 가장 높게 나타나(평균 $dCor \approx 0.423$), 모델이 기후 스트레스에 대한 즉각적인 급성 건강 영향을 시의적절하게 반영하고 있음을 확인.

Rank	Health Indicator	Distance Correlation	95% CI	p-value*	Lag (years)	Coverage Period
1	Per-capita Summer HRI	0.449	[0.314, 0.605]	<0.001*	0	2015-2019
2	Per-capita Annual HRI	0.422	[0.293, 0.598]	<0.001*	0	2015-2019
3	Per-capita Summer ED Visits	0.397	[0.304, 0.532]	<0.001*	0	2015-2019
4	Annual HRI Cases	0.321	[0.250, 0.509]	0.058	3	2015-2019
5	Summer HRI Cases	0.316	[0.233, 0.512]	0.026*	2	2015-2019
6	Summer ED Visits	0.219	[0.215, 0.455]	0.427	3	2015-2019



15

그림 12. 외부 건강 데이터로 검증한 결과입니다. 표는 건강지표별 거리상관과 신뢰구간, 시차를 정리한 것이고 오른쪽 막대그래프는 그 크기를 비교한 것입니다. 인구당 여름철 온열질환에서 0.449로 가장 높았고, 시차 0년에서 가장 강하게 나타났습니다.

흥미로운 건 상위 지표가 모두 '인구당' 값이었다는 점입니다. 단순 발생 건수는 인구가 많은 동네에서 당연히 커지므로, 지역 간 비교에는 인구 보정이 필수라는 실무적 교훈도 함께 얻었습니다.

8. 데이터는 어디서, 무엇을 썼나요

궁금해하실 분들을 위해 정리하면, 서울시를 대상으로 총 13,170 개의 시공간 관측치를 구성했습니다. 지역 단위로 잘라 여러 해에 걸쳐 쌓은 데이터입니다. 변수는 AR6 네 요소에 맞춰 16 개를 사용했습니다.

- **위해:** 폭염일수, 열대야, 온난기간 지속일수, 지표면온도(위성 관측)

- **노출**: 인구밀도, 건물밀도, 불투수면 비율, 지하주거
- **취약성**: 고령인구, 영유아, 저소득층
- **적응역량**: 녹지율, 무더위쉼터 밀도, 의료 접근성, 냉방 전력, 대중교통 접근성


02. 연구 방법

1 데이터 및 연구 프레임워크

- Sensitivity: 동일한 노출 수준에서도 더 큰 피해를 입을 수 있는 인구 집단의 특성
- Adaptive Capacity: 폭염에 대응하고 피해를 완화할 수 있는 지역사회의 능력을 측정
- Exposure: 폭염에 직접적으로 노출된 인구와 자산의 공간 분포
- Hazard: 물리적인 극한 기후 현상의 강도
- Risk: IPCC AR6의 프레임워크를 GAT 아키텍처 내 Cross-Component Attention으로 구현하여, 각 컴포넌트 간 비선형 상호작용을 데이터 기반으로 학습하는 통합 리스크 지표



Component	Variable	Unit
Climate Hazard	Heat wave days	days
	Tropical nights	nights
	Warm spell duration	days
	Land surface temp	°C
Urban Exposure	Population density	persons/km ²
	Impervious surface	%
	Building density	%
	Transport access	dimensionless
Social Sensitivity	Underground housing	%
	Young children	%
	Low income	%
	Elderly population	%
Adaptive Capacity	Summer cooling elec.	kWh/household
	Healthcare access	dimensionless
	Green space	m ² /person
	Heatwave shelter	facilities/10k pop



05

그림 13. 연구에 사용한 변수 구성과 공간 분포입니다. 왼쪽 표가 AR6 네 요소별 변수 목록이고, 오른쪽 네 개의 지도는 대표 변수들이 서울 안에서 어떻게 분포하는지를 보여줍니다. 같은 서울인데도 변수마다 뜨거운 곳이 서로 다르다는 점을 확인할 수 있습니다.

재미있는 발견 하나. XAI가 뽑은 상위 변수에 **대중교통 접근성**이 계속 올라왔습니다. 처음엔 의외였는데, 생각해 보면 자연스럽습니다. 교통 접근성이 좋다는 건 사람이 많이 모이고 개발이 집약된 곳이라는 뜻이고, 그건 곧 아스팔트와 건물이 많다는 의미이기도 하니까요. 데이터가 도시의 구조를 대신 말해주고 있었습니다.

9. 이 연구가 남긴 것

정리하겠습니다. 이 연구가 한 일은 세 가지입니다.

첫째, 국제적으로 합의된 이론(IPCC AR6)을 AI 모델 구조에 직접 구현했습니다. 가중치를 사람이 임의로 정하는 문제를 이론으로 대체했습니다.

둘째, 정확도와 설명력을 함께 확보했습니다. 엄격한 검증에서 R^2 0.9681 을 유지하면서, 세 가지 XAI 로 89.6% 일치하는 해석을 제시했습니다. 그리고 외부 건강 데이터로 실제 피해와의 연관성까지 확인했습니다.

셋째, 스케일에 따라 위험의 지배 요인이 바뀐다는 사실을 발견했습니다. 이건 단순한 기술적 결과가 아니라, 정책의 시간 지평(장기 구조 개선 vs 단기 대응)을 나누어 설계해야 한다는 실천적 함의를 갖습니다.

04. 결론

1 결론 및 제언

- ✓ IPCC 이론 기반의 설명가능한 시공간 GAT 모델 구축
- ✓ 다차원적 검증을 통한 모델 신뢰성 및 강건성 확보
- ✓ 도시 기후 리스크의 스케일 의존적 이중 구조 확인

- 01 도시 구조와 기후 위기
어디가 위험한가(구조적 취약성)와 언제 위험한가(시급성)가 분석 스케일에 따라 다르게 나타남을 입증하였음. 이는 단일 해법이 아닌, 스케일별로 차별화된 접근이 필요함을 시사
- 02 구조적 불평등 해소를 위한 장기 전략
서울시 전체 차원에서는 리스크 격차의 주범인 도시 노출도(불투수면, 건물밀도)를 낮추기 위해, 녹지 확충 및 바람길 조성 등 도시 계획적 차원의 장기적인 구조 개선 노력이 선행되어야 함.
- 03 직면한 위험에 대한 맞춤형 단기 대응 전략
개별 자치구 차원에서는 당장의 폭염 강도(Hazard)가 지배적이므로, 취약계층 중심의 쿨링센터 접근성 개선, 실시간 폭염 경보 시스템 고도화 등 지역 맞춤형 단기 적응 정책이 시급함.
- 04 데이터 기반의 다층적 기후정의 구현
과학적 증거에 기반하여 공간적(지역 간 균형) · 사회적(취약계층 보호) 형평성을 모두 고려한 포용적 기후정의 정책 수립의 핵심 도구

16

그림 14. 결론 슬라이드입니다. 도시 구조와 사회 취약성이 지역 간 격차를 만들고, 미시적 기후 강도가 실제 위험 크기를 결정하며, 설명가능 AI 가 이 둘을 근거와 함께 제시할 수 있다는 것이 이 연구의 결론입니다.

개인적으로는, "AI 로 예측했습니다"에서 멈추지 않고 "그래서 왜 그런지 말할 수 있습니다"까지 갔다는 점이 가장 뿌듯합니다. 정책은 숫자만으로 움직이지 않고 설명으로 움직이니깐요. 담당 공무원이 "이 동네를 먼저 챙겨야 합니다. 이유는 이것입니다"라고 말할 수 있어야 예산이 움직입니다.

앞으로는 이 틀을 도시 폭염에서 **산림 재해**로 옮기는 작업을 하고 있습니다. 산불 뒤에 산사태가 따라오는 연쇄 재해를 같은 방식으로, 즉 위성과 설명가능 AI 로 예측하고 근거를 함께 제시하는 연구입니다. 그 이야기는 다음에 따로 정리해 보겠습니다.

긴 글 읽어주셔서 감사합니다. 궁금한 점이나 데이터·방법에 대해 더 알고 싶은 부분이 있으면 댓글로 남겨주세요.

논문 정보

Choi, H., Park, J. S., & Lim, C.-H. (2026). Climate justice through explainable graph neural networks: A spatiotemporal attention-based urban heat risk assessment under IPCC AR6 framework. **Urban Climate**, Article 102981.

DOI: <https://doi.org/10.1016/j.uclim.2026.102981>

링크 · 포트폴리오 <https://portfolio-eight-ruddy-87.vercel.app> · GitHub
<https://github.com/zxsa0716>